学号：202110310148

上海海事大学

本科毕业论文(设计)

论文题目：基于扩散模型的图像修复

姓　　名：钱毅

学　　院：信息工程学院

专　　业：人工智能

班　　级：211

指导教师：胡政伟

完成时间：2025 年 5 月

论文独创性声明

本论文是我个人在导师指导下进行的研究工作及取得的研究成果。论文中除了特别加以标注和致谢的地方外，不包含其他人或者其他机构已经发表或撰写过的研究成果。其他同志对本研究的启发和所做的贡献均已在论文中作了明确的声明并表示了感谢。

作者签名：戚毅 日期：2025.5.14

论文版权使用授权书

本论文作者完全了解学校有关保留、使用论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权上海海事大学可以将本论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本论文。

本论文属于(请在以下相应方框内打“√”)：

☐ 保密，在　　年解密后适用本使用授权书。

☑ 不保密。

作者签名：戚毅 导师签名：[illegible] 日期：2025.5.14

摘　要

近年来，图像修复一直是计算机视觉领域的研究热点，其通过有效地填补、重建和还原图像中受损或缺失的内容，使图像重新具备清晰度与完整性，在文化遗产保护、影视娱乐制作、医学影像诊断等领域发挥重要作用。

图像修复的研究通常关注以下三个问题：(1) 修复区域与原始图像的语义一致性问题；(2) 纹理细节模糊问题；(3) 模型泛化能力不足导致在实际场景中性能下降的问题。目前主流的生成对抗网络（Generative Adversarial Networks, GAN）和注意力机制（Attention Mechanism）虽然在一定程度上增强了修复区域与原图的语义联系，但生成结果常因语义理解不充分而产生不协调现象。针对以上问题，本文以扩散模型为基础，根据文本提示对指定区域进行图像修复，将预训练的 Stable-Diffusion-XL 模型权重进行微调，通过对模型的输入格式进行改进以匹配适用于文本引导图像修复任务，并调试参数在不同数据集进行微调以找到最佳方案以适应特定下游任务，在 Brvcket 和 MSCOCO 数据集上的实验结果表明，本文采用的模型和微调方法可显著提高图像修复质量。

关键词：深度学习；图像修复；扩散模型；Stable-Diffusion-XL

Abstract

In recent years, image inpainting has become a research hotspot in the field of computer vision. By effectively filling in, reconstructing, and restoring damaged or missing content in images, it restores clarity and completeness, playing a vital role in areas such as cultural heritage preservation, film and television production, and medical imaging diagnostics.

Current image inpainting research generally focuses on three main issues: (1)semantic consistency between restored regions and the original image; (2)blurry texture details; (3)insufficient generalization capability, which leads to performance degradation in practical scenarios. To address the issue of semantic consistency, mainstream approaches such as Generative Adversarial Networks (GANs) and Attention Mechanisms have improved the semantic correlation between the inpainted regions and the original image to some extent. However, inconsistencies often still arise due to insufficient semantic understanding.

To tackle these problems, this paper proposes a diffusion model-based approach for text-guided image inpainting. The method involves fine-tuning the pretrained Stable Diffusion XL model by modifying the input format to better suit text-guided inpainting tasks. The model is then fine-tuned on different datasets by adjusting parameters to identify the optimal configuration for specific downstream tasks.Experiments conducted on the Brvcket and MSCOCO datasets demonstrate that the proposed model and fine-tuning strategy significantly improve image inpainting quality.

KeyWords: deep learning; image inpainting;Diffusion model;Stable-Diffusion-XL

目　录

1　绪论 1
1.1　研究背景与意义 1
1.2　国内外相关研究 2
1.2.1　基于传统图像处理的方法 2
1.2.2　基于深度学习的方法 3
1.2.3　图像修复面临的挑战 4
1.3　本文的创新点 4
1.4　本文的结构安排 4
2　相关技术概述 6
2.1　变分自编码器 VAE 6
2.2　生成式对抗网络 GAN 6
2.3　去噪扩散模型 DDPM 7
2.4　VAE、GAN、DDPM 比较 8
3　基于 Stable-Diffusion-XL 的图像修复 10
3.1　扩散模型在图像修复中的原理 10
3.1.1　扩散模型基础 10
3.1.2　前向扩散与逆向扩散 10
3.1.3　扩散模型用于图像修复的原理 11
3.2　Stable-Diffusion-XL 用于图像修复 12
3.2.1　Stable-Diffusion 基本原理 12
3.2.2　基于 SDXL 的图像修复任务微调 13
3.3　系统框架图 14
4　实验与分析 16
4.1　数据集与计算环境 16
4.1.1　数据集 16
4.1.2　数据预处理 17
4.1.3　计算环境 18
4.2　实验评估方法 18
4.3　实验结果分析 19

4.4 微调参数对比实验 22
4.5 可视化分析 28
5 总结与展望 31
5.1 总结 31
5.2 展望 31
致 谢 33
参考文献 34

1 绪论

1.1 研究背景与意义

随着数字图像技术的快速发展，人们越来越频繁地使用数字图像来记录、传输和交流信息，图像质量的高低直接关系到信息传递的准确性和有效性。然而，在实际应用中，由于拍摄环境中的光照条件、采集设备性能限制、数据传输过程中的噪声干扰，以及设备故障、人为操作失误和存储设备失效等因素，图像往往会出现各种形式的损伤与缺陷。这些损伤包括但不限于像素损坏、图像失真、噪声干扰等问题。这些问题不仅严重降低了图像的视觉质量，还可能导致图像中信息的错误传递甚至识别困难，直接影响了图像的实际应用价值。

面对图像损伤带来的诸多挑战，图像修复技术逐渐成为了一个重要的研究方向。图像修复的目标在于恢复图像中缺失或损坏的细节，从而有效提高图像质量和整体可用性，修复过程通常通过挖掘图像中潜在的信息，即利用待修复区域周边的局部信息以及图像整体的大局信息，合理推断缺损区域应有的视觉内容，使修复后的图像看起来更加真实自然，并与原图上下文紧密融合。

图像修复技术在多个实际应用场景中展现出重要价值，其发展对社会、科技和工业各领域均具有深远影响。例如，在文化遗产保护领域，如图 1.1(a)，图像修复能够恢复受损的艺术品、历史文献和照片，促进文化的传承与历史研究；在影视娱乐产业，如图 1.1(b)，修复技术可用于消除拍摄过程中的瑕疵和不必要的元素，提升影视作品的视觉效果；在个人隐私保护方面，社交媒体用户可以借助图像修复技术移除敏感信息，保障个人隐私安全；在医学影像领域，如图 1.1(c)，图像修复有助于提高影像质量，从而帮助医生更准确地进行诊断和治疗；在艺术创作与设计领域，如图 1.1(d)，创作者可以利用图像修复技术实现丰富的创意表达，创造出独特的视觉效果；在商业应用方面，各类图像编辑软件和在线平台可借助图像修复技术满足更广泛的用户需求。此外，图像修复与自动驾驶、机器人视觉等前沿领域的结合，也将为这些领域的发展提供崭新的技术支持和解决方案。

(a) 文化遗产保护

(b) 广告元素移除

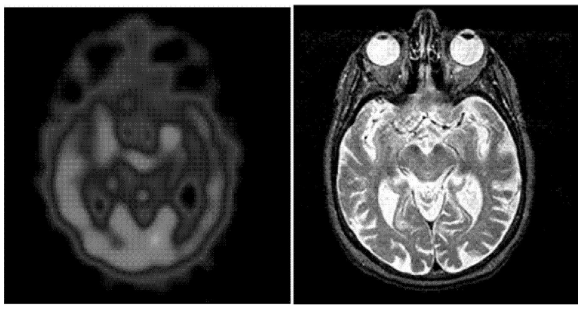

(c) 医学影像处理

(d) 艺术创作

图 1.1 图像修复应用领域

然而，传统的图像修复方法在处理复杂图像损伤问题时往往效果有限，难以满足日益增长的实际需求。因此，人工智能技术特别是深度学习方法近年来被广泛引入图像修复领域，显著提升了修复的质量与稳定性。尤其是近年来涌现的大型文本到图像扩散模型，在图像生成任务中展现出了巨大的潜力，其稳定的训练过程与出色的生成能力为图像修复领域带来了新的可能性。

综上所述，本文正是基于上述背景，着力探索如何进一步优化基于扩散模型的图像修复方法，尤其关注在文本引导的对象修复任务中的表现，以期达到更佳的图像修复效果。

1.2 国内外相关研究

近年来，随着图像修复在医疗诊断、文化保护、社交媒体等领域的广泛应用，国内外许多研究者围绕如何利用人工智能相关技术更有效地实现图像修复任务展开了深入研究，并提出、构建了多种修复模型，为图像缺损恢复的实现提供了坚实的理论基础与技术支持。按照技术演进路径与研究核心内容进行分类，图像修复方法主要可以分为基于传统图像处理技术的方法和基于深度学习的方法，以下将从这两个方面综述国内外在图像修复领域的相关研究成果。

1.2.1 基于传统图像处理的方法

传统图像修复方法主要包括插值、边缘检测和纹理合成等技术。

插值法是一种基本的图像修复技术，通常用于较小区域的缺损填充，其核心思想是利用待修复区域周围已知像素的灰度值，通过数学函数预测缺失像素的数值。例如线性插值、双线性插值和三次样条插值法都广泛应用于图像处理任务中。然而，插值法往往会造成修复区域模糊，特别是在图像细节丰富或纹理复杂的区域[1]。

边缘检测技术则主要针对图像结构的恢复，通过提取图像中的边缘信息，有效保持结构的连续性和准确性。Canny 边缘检测、Sobel 和 Prewitt 算子均是经典的边缘检测方

法，能较好地保护修复区域的结构特征。但此类方法对噪声较敏感，边缘检测不准确时可能导致修复效果不理想[2]。

纹理合成技术旨在通过从图像的已知区域提取纹理样本，来填充修复区域。Efros 和 Leung[3]提出了一种非参数化的纹理合成方法，该方法通过从已知纹理区域随机选择匹配的纹理片段填充空洞区域，从而产生视觉连贯的修复效果。Criminisi 等[4]提出的基于纹理合成与结构传播的方法进一步结合了图像结构信息与纹理信息，有效提升了图像修复的自然度。然而，这些纹理合成方法仍存在明显的局限性，如无法准确恢复复杂结构或大面积缺损的图像，且容易产生重复性和不自然的修复痕迹。

此外，Bertalmio 等[5]提出了偏微分方程的(Bertalmio-Sapiro-Caselles-Ballester, BSCB)模型，利用图像的局部信息，通过等照度线将已知区域的信息传播到待修复区域，但对于大面积的缺失情况修复效果不佳。

综上所述，传统图像修复方法的局限性主要在于其过于依赖图像空间上的冗余信息，忽略了图像的高层语义内容，因而在修复大规模损坏或结构复杂的图像时，修复质量往往欠佳，修复结果容易出现模糊和断层等视觉缺陷。

1.2.2 基于深度学习的方法

深度学习的快速发展显著提升了图像修复技术的性能，在鲁棒性和泛化性等方面均取得了突破性进展。近年来，深度学习模型成为研究图像修复的重要工具，主要包括变分自编码器(VAE)、生成对抗网络(GAN)以及扩散概率模型(DDPM)等方法。

Diederik P 等人[6]提出变分自编码器(variational auto-encoder,VAE)引入了概率模型的思想，将自编码器与概率分布相结合，通过显式的概率建模，将高维数据映射到潜在空间中，实现对数据分布的有效捕获。这种方法不仅能生成多样化的图像，还具有良好的潜在空间连续性和可解释性，成为后续图像修复和生成研究的重要基础。

Ian Goodfellow 等人[7]提出了生成对抗网络(GAN)，GAN 通过引入生成器与判别器之间的对抗机制，实现了图像生成质量的显著提升，彻底改变了图像生成与修复的研究范式，标志着图像生成领域的革命性突破，为后续模型发展衍生提供理论基础。然而，原始 GAN 在训练过程中易出现模式崩溃（mode collapse）及训练不稳定的问题。为解决这些问题，研究人员提出了许多改进 GAN 的方法，如深层生成对抗网络(DCGAN)[8]、条件生成对抗网络(CGAN)[9]、Wasserstein GAN(WGAN)[10]等，以解决 GAN 训练中的稳定性和模式崩溃等问题。这些改进方法在一定程度上缓解了原始 GAN 的不足，推动了 GAN 在图像修复领域的广泛应用。

近年来，扩散概率模型（Denoising Diffusion Probabilistic Models, DDPM）逐渐成为图像生成领域新的研究热点。DDPM 由 Jonathan Ho 等人于 2020 年提出，通过逐步添加和移除噪声的方法，建立了一种稳健且易于控制的生成过程[11]。相比于 GAN，DDPM

有效避免了模式崩溃和训练不稳定的问题，且在图像生成的多样性和质量控制方面具有明显优势。因此，DDPM 迅速引起了研究者的关注，并逐渐成为图像修复任务中最具潜力的方法之一。

在 DDPM 的基础上，Dustin Podell 等人提出了稳定扩散 XL（Stable Diffusion XL, SDXL）模型[12]。SDXL 进一步结合了潜在扩散模型和高效的潜在空间编码策略，在高分辨率图像生成和图像修复任务中表现出卓越的能力，有效提升了图像修复结果的视觉效果与细节保真度。

1.2.3 图像修复面临的挑战

综上所述，针对图像修复任务的研究受到了国内外学者和工程人员的重视，尽管深度学习方法在图像修复领域取得了显著进展，但目前仍然存在一些亟待解决的挑战：

（1）图像修复过程中难以准确保持图像语义一致性，尤其是在复杂结构或包含多个语义对象的场景下，容易产生不合理或不自然的修复结果；

（2）现有模型在大规模缺损或高分辨率图像修复时存在生成效率低下和细节不清晰等问题。

本文将基于以上背景和挑战，在先前研究的基础之上，通过对稳定扩散大模型 SD XL 进行微调，尝试解决图像修复任务中语义一致性差和高分辨率图像细节不足两个关键问题，旨在提高模型在特定场景下图像修复的语义准确性和视觉质量。

1.3 本文的创新点

本文针对图像修复任务，在稳定扩散 XL（Stable Diffusion XL,SDXL）[12]预训练模型的基础上进行了针对性的微调和创新设计，具体创新点如下:

（1）扩展 U-Net 输入通道

本文创新性地在 U-Net 结构中新增了 5 个额外的输入通道，其中 4 个通道用于编码后的遮罩混合图像，另 1 个通道用于遮罩本身。这种设计能够有效增强模型对于待修复区域图像细节的感知能力，显著提高修复结果的视觉质量与细节准确性。

（2）引入空间位置信息

在模型输入中计算了额外的时间标识，提供给模型额外的空间位置信息。这种创新设计帮助模型更准确地定位和恢复被遮挡区域的图像内容，从而进一步提升图像修复任务的语义一致性与修复质量。

1.4 本文的结构安排

本文围绕特定数据场景下的图像修复任务展开，拟采用 SDXL 大模型作为主体模型，通过改进的模型输入和微调手段，探究其应用于特定数据场景下图像修复的功效，通过对比不同参数下的效果并与其他模型比较，验证模型的性能。全文的主要工作和结构安排如下：

第一章为绪论，对图像修复的研究背景、实现图像修复的意义展开概述，从传统图像处理方法和基于深度学习的方法切入，对国内外研究进行概述，并提总结本文待解决的问题，最后对本文的组织结构进行了介绍。

第二章的研究工作围绕基于深度学习的图像修复方法展开详细介绍与对比。重点介绍了变分自编码器(VAE)、生成对抗网络(GAN)和去噪扩散模型(DDPM)三种主要模型。详细比较了三种模型的特点和适用场景，指出 VAE 适合捕捉数据潜在结构，GAN 擅长高分辨率和细节修复，DDPM 则在复杂修复任务中表现突出。为后续研究提供了方法论和理论基础。

第三章在 DDPM 的基础上，展开 SDXL 的模型原理，并在 SDXL 的基础上研究如何在图像修复任务上进行创新，在输入端增加了对掩码 mask 信息的处理。训练时将原始图像、经过 mask 处理的图像以及 mask 自身的潜在表示拼接在一起，从而引导模型专注于修复缺失区域。除了常规的文本条件外，还计算了额外的时间标识(time_ids)，该信息基于原始图像尺寸和裁剪起始坐标生成，为模型提供了空间位置信息，帮助更准确地恢复被遮挡区域。

在第四章中，先在 Brvcket 数据集上设计对比实验，通过不同的微调参数设置，例如学习率、预热步数、学习率调度器、SNR 信噪比、权重衰减系数等，进行结果对比。接着，选用最佳参数设置在 MSCOCO 上迭代训练 20k 步，观察修复效果。最后针对结果进行定性分析，结合数据集特点找到问题产生的原因。

在第五章中，对本文方法和实验结果进行总结，同时，指出本文工作仍存在的缺陷以及下一步研究的展望。

2 相关技术概述

本章主要综述了图像修复领域的相关技术，主要包括变分自编码器 VAE、生成式对抗网络 GAN 和去噪扩散模型 DDPM，简要介绍了三种方法的技术原理，并分析比较模型各自的优势和局限性，并对这三种方法进行了系统比较。

2.1 变分自编码器 VAE

变分自编码器(VAE)是一种生成模型，旨在学习数据分布的潜在结构，它结合了自编码器和概率图模型的思想。它通过学习将输入数据映射到潜在空间的分布，并在潜在空间中进行采样，从而生成新的数据样本。VAE 由编码器和解码器组成。编码器将输入图像编码为低维的隐空间表示(隐变量)，解码器则将隐变量解码为图像。在图像修复中，损坏的图像区域被编码为隐变量，然后通过解码器生成修复后的图像。如图 2.1 所示，编码器将输入数据 x 映射到一个低维的潜在空间表示 z。解码器则是将潜在空间表示 z 重构回原始数据空间，得到重构数据，整个过程就像是对数据进行了一次“压缩-解压”操作，其中参数μ是均值，参数σ是标准差，用于描述潜在变量的概率分布。

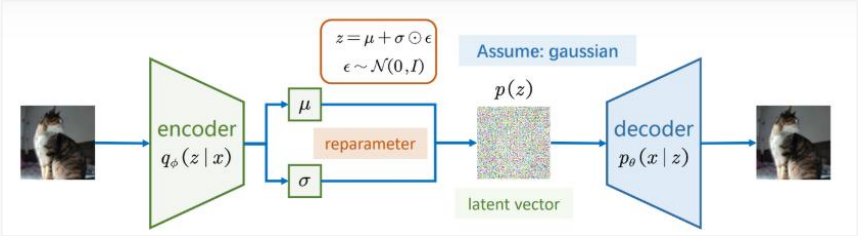

图 2.1 变分自编码器 VAE

在图像修复领域，VAE 被广泛用于生成缺失或破损图像的合成内容出现了一些关键研究成果。Conditional Variational Autoencoder(CVAE)[13]是对标准 VAE 的扩展，它引入了条件信息，使得模型能够生成特定条件下的图像修复结果。这对于需要根据上下文进行修复的任务非常有用。β-VAE[14]是一种对标准 VAE 进行改进的方法，通过引入一个超参数β，控制潜在表示的独立性，这可以帮助生成更具有解释性和可操作性的潜在表示，对于图像修复的结果更具有控制性。

2.2 生成式对抗网络 GAN

生成对抗网络(GAN)是一种深度学习模型，最初由 Ian Goodfellow 等人[7]于 2014 年提出。GAN 的核心思想是通过训练两个神经网络，一个生成器和一个判别器，彼此协同学习以生成逼真的数据。

如图 2.2，生成器的目标是从噪声或已知图像内容中生成修复后的图像。在图像修复任务中，生成器通常接收图像的损坏部分作为输入，并输出修复后的完整图像。判别

器的目标是区分生成器生成的图像与真实图像。通过对抗训练，判别器不断优化以识别生成图像中的不自然部分，而生成器则努力生成更逼真的图像。在训练过程中，生成器和判别器相互对抗，生成器不断学习如何生成更接近真实图像的内容，而判别器则不断学习如何区分真假图像。最终，生成器能够生成高质量、自然的修复结果。

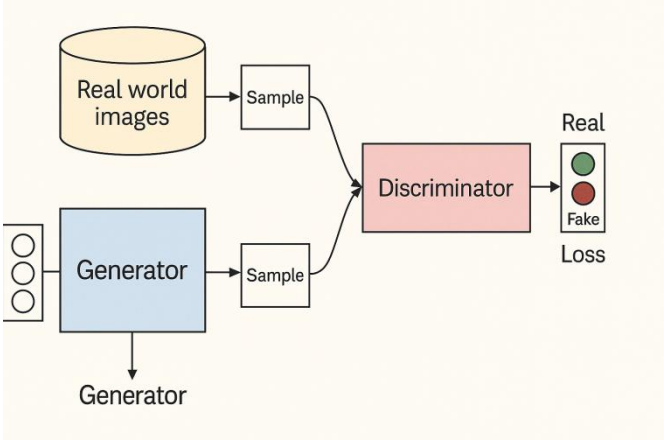

图 2.2　生成对抗式网络 GAN

基于 GAN 的图像修复任务先后有过许多研究。Pix2Pix[15]是一种基于条件 GAN 的图像转换方法，被广泛用于图像修复，通过将输入图像和目标图像作为条件输入，可以生成逼真的修复结果，这在处理结构性图像修复任务时取得了良好的效果，比如去雨、去雾等。CycleGAN[16]是另一种 GAN 的变体，可以学习在不同域之间进行转换，而无需成对的训练数据。这使得它在一些无监督或缺乏匹配数据的图像修复任务中表现出色。但 GAN 的训练中往往存在模式崩溃或训练不稳定等问题。

2.3　去噪扩散模型 DDPM

扩散模型是一种基于逐步生成的概率模型，通过正向扩散和逆向去噪过程来生成数据。如图 2.3，正向扩散过程是从真实图像逐步添加噪声，最终将其转化为高斯噪声 x_t 的过程。每一步添加的噪声量由预定义的噪声调度参数 β_t 控制。

$$q(x_t|x_{t-1}) = N(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I) \tag{2.1}$$

逆向生成是正向扩散的逆过程，从纯噪声开始逐步去噪，最终生成清晰的图像。模型通过学习条件概率分布 $p_\theta(x_{t-1}|x_t)$ 来实现去噪，其中 μ_θ 和 Σ_θ 是通过神经网络学习得到的参数。

$$p_\theta(x_{t-1}|x_t) = N(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t)) \tag{2.2}$$

扩散模型的训练目标是最小化去噪误差，即预测噪声的误差。具体来说，模型需要学习预测正向扩散过程中添加的噪声ϵ，从而逐步恢复出原始图像。

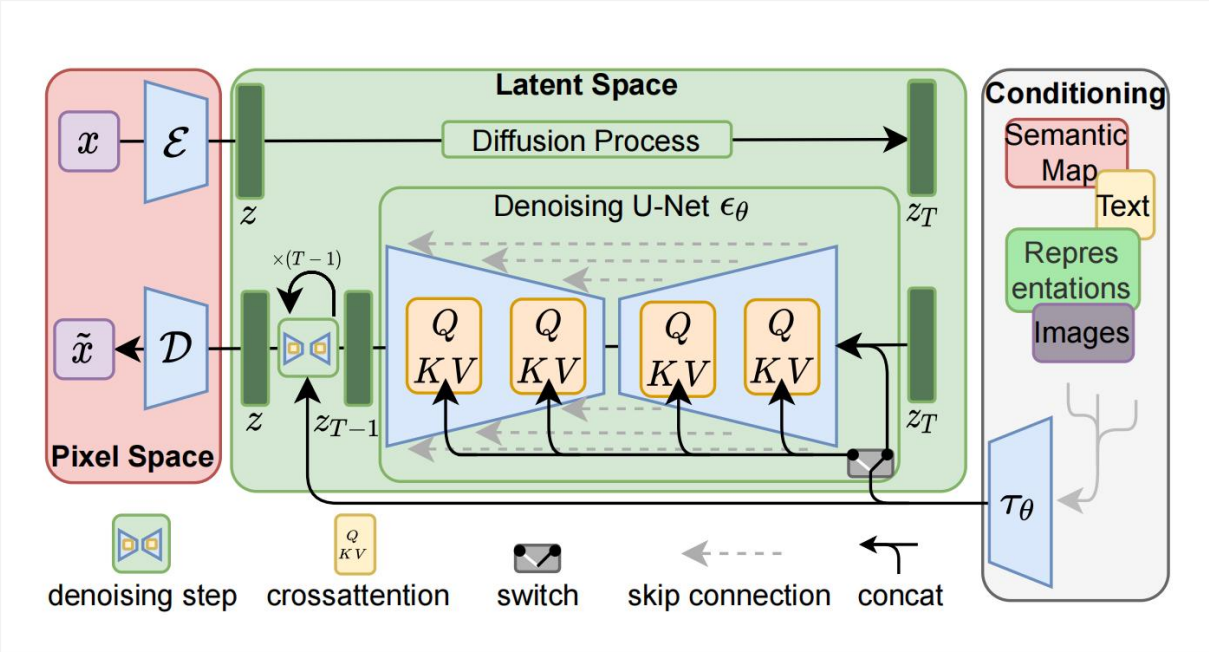

图 2.3　去噪扩散模型[17]

扩散模型以其强大的去噪能力和高质量的生成效果，在图像修复领域展现出巨大的潜力。无论是去除噪声、修复缺失区域，还是去除伪影，扩散模型都能提供自然且高质量的修复结果。相对于 GAN，它们不需要同时训练生成器和判别器两个网络，而是通过预定义的扩散过程来模拟图像生成的步骤。这有助于避免 GAN 训练中出现的模式崩溃或训练不稳定的问题，在生成过程中具有更好的多样性控制能力。通过调整扩散过程中的步骤数或温度参数，可以控制生成的图像样本的多样性，而不会像 GAN 那样容易出现模式崩溃。而且扩散模型通常具有更强的可解释性，它们基于概率模型，可更清晰地表达生成过程中每个步骤的概率分布。尽管扩散模型具有许多优势，但也存在一些挑战，比如对于大规模数据的处理和复杂模式的建模能力可能会受限。

2.4　VAE、GAN、DDPM 比较

当前神经网络在图像修复领域的研究主要集中在 变分自编码器(VAE)、生成对抗网络(GAN)和扩散模型这三个关键方向。这些技术各具特点，并在不同的应用场景中展现出独特的优势。

变分自编码器(VAE)是一种基于概率建模的生成方法，它通过编码器将输入数据映射到潜在空间，并利用解码器重构原始图像。在图像修复任务中，VAE 通过学习数据的概率分布来填补缺失区域，使其能够较为有效地处理不完整图像。由于 VAE 强调对数据分布的建模能力，因此在需要明确理解数据结构的任务中具有一定优势。然而，由于其解码过程中可能引入模糊，VAE 在生成高分辨率和细节丰富的图像方面仍存在一定的局限性。

生成对抗网络(GAN)采用对抗训练策略，由生成器和判别器组成，二者相互博弈，以不断提升生成图像的质量。GAN 在高分辨率图像修复、面部重建等任务中表现优异，能够生成极具真实感的细节和纹理，使修复后的图像更加自然。然而，由于 GAN 训练过程复杂，易受模式崩溃(mode collapse)影响，导致生成结果的多样性受限，因此在训练时通常需要较强的调优能力。

去噪扩散模型(DDPM)通过逐步向数据添加噪声，再学习如何逆转这一过程来实现数据生成。该方法在高度损坏或缺失信息较多的图像修复任务中表现突出。扩散模型的主要优势在于其强大的生成能力，可以处理复杂的修复任务，并生成高质量的修复结果。然而，与其他方法相比，扩散模型的计算成本较高，推理速度较慢，这在实际应用中可能成为限制因素。

综上所述，VAE 适用于理解数据分布的任务，GAN 在高分辨率修复场景中表现优异，而扩散模型则在处理严重损坏的图像时具备优势。

表 2.1 VAE、GAN 和扩散模型的主要差异

特征	VAE	GAN	扩散模型
目标	生成数据的潜在表示	生成逼真的数据	通过扩散过程建模数据分布
生成过程	通过学习数据分布的潜在表示，从中采样生成新数据	通过训练生成器和判别器的博弈，生成逼真的数据	利用随机扩散过程模拟数据生成
训练方式	最大化潜在表示的似然概率	生成器和判别器的对抗训练	最小化扩散过程中的损失函数
损失函数	重建损失+正则项	对抗损失(生成器和判别器之间)	扩散过程中的负对数似然损失
数据表示	潜在空间中的编码表示	无明确潜在表示	不涉及潜在表示
训练稳定性	相对稳定	训练过程可能不稳定	相对稳定
应用领域	图像生成/特征学习	图像生成/样式迁移	图像生成/去噪

3 基于 Stable-Diffusion 的图像修复

本章介绍了扩散模型与 Stable-Diffusion-XL 在图像修复任务中的应用，详细阐述了前向扩散与逆向扩散的理论基础，分析了 SDXL 模型的关键改进点，并给出了本文所提出图像修复系统的整体架构与技术流程。

3.1 扩散模型在图像修复中的原理

3.1.1 扩散模型基础

扩散模型通过一个前向扩散过程(Forward Diffusion Process)，将图像逐渐增加随机噪声，直至转化为纯随机噪声。在反向扩散过程 (Reverse Diffusion Process)中，模型学习去噪策略，逐渐恢复原始图像，以实现图像生成和修复。

图像修复任务中，该模型根据传入的掩码 Mask，在指定区域内扩散，而在其他区域保持不变，它通过对此区域逐渐生成一个与图像全局保持一致性的充填部分，以达到真实的修复效果。

3.1.2 前向扩散与逆向扩散

扩散模型定义了如图 3.1 所示的正向和逆向两个过程，正向过程或称扩散过程是从真实数据分布采样，逐步向样本添加高斯噪声，生成噪声样本序列，加噪过程可用方差参数控制，可近似等同于一个高斯分布。其扩散过程是预设的可控过程，加噪过程可用条件分布表示为公式(3.1)。

$$q(x_t|x_{t-1}) = \mathrm{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I) \tag{3.1}$$

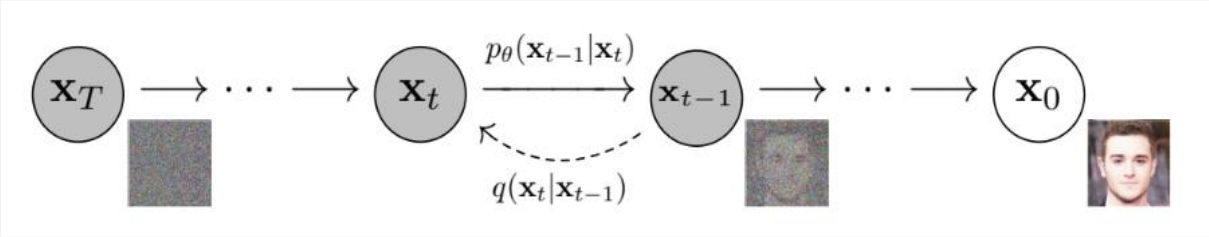

图 3.1 扩散模型的扩散过程示意图

公式(3.1)的意思是：由 x_{t-1} 得到的 x_t 的过程 $q(x_t|x_{t-1})$ 满足分布 $\mathrm{N}(x_t; \sqrt{1-\beta_t}x_{t-1}, \beta_t I)$ 这个噪声只由 β_t 和 x_{t-1} 来决定，是一个固定值而不是一个可学习过程。只要有了 x_0，并且提前确定每一步的固定值 $\beta_1,...,\beta_T$，就可以推出任意一步的加噪数据 $x_1,...,x_T$。这里正向加噪过程是一个马尔科夫链过程。随着 t 不断增大，原始数据 x_0 会逐步失去它的特征。最终当 $T \to \infty$ 时，x_T 趋近于一个各向独立的高斯分布。从视觉上来看，就是将原本一张

完好的照片加噪很多步后，图片几乎变成了一张完全是噪声的图片。从上述扩散过程的定义可以看出，在任意时间步长t上使用公式(3.1)可以推导得到公式(3.2)进行采样。

$$x_t = \sqrt{\alpha_t} x_{t-1} + \sqrt{1-\alpha_t} z_{t-1} = \ldots = \sqrt{\overline{\alpha_t}} x_0 + \sqrt{1-\overline{\alpha_t}} z_0 \tag{3.2}$$

$$\alpha_t = 1-\beta_t, \overline{\alpha_t} = \prod_{i=1}^{t} \alpha_i, z_* \sim \mathrm{N}(0, I) \tag{3.3}$$

同样可以把扩散过程逆向，从高斯噪声中采样，如果能将上述过程转换方向，即从$q(x_{t-1}|x_t)$中采样，那么就可以从一个随机的高斯分布$\mathrm{N}(0,I)$中重建出一个真实的原始样本，也就是从一个完全杂乱无章的噪声图片中得到一张真实图片。但是，由于需要从完整数据集中找到数据分布，无法很简单地预测$q(x_{t-1}|x_t)$，需要要学习一个模型p_θ来近似模拟这个条件概率，从而运行逆扩散过程，因此逆向过程可定义为公式(3.4)、(3.5)。

$$p_\theta(x_{\theta:T}) = p(x_T) \prod_{t=1}^{T} p_\theta(x_{t-1}|x_t) \tag{3.4}$$

$$p_\theta(x_{t-1}|x_t) = \mathrm{N}(x_{t-1}; \mu_\theta(x_t,t), \Sigma_\theta(x_t,t)) \tag{3.5}$$

公式(3.5)中，$\mu_\theta(x_t,t)$是神经网络预测的图像值，$\Sigma_\theta(x_t,t)$是当前的噪声应当每个时间步的信保区间。该模型通过对每步过程进行查断并修正，自上下文中加入属于被修复区域的信息，逐渐恢复图像信息。

3.1.3 扩散模型用于图像修复的原理

在图像修复任务中，扩散模型被用于填补图像缺失区域，使生成的内容与原图保持一致。传统的扩散模型在逆向扩散过程中 均匀地去噪，但对于图像修复任务，需要特别关注受损区域(mask 区域)的信息恢复。为此，Lugmayr[18]等人在 RePaint 论文中提出了一种重采样扩散(RePaint Diffusion)方法，如图 3.2 所示，以优化扩散模型在图像修复中的表现。

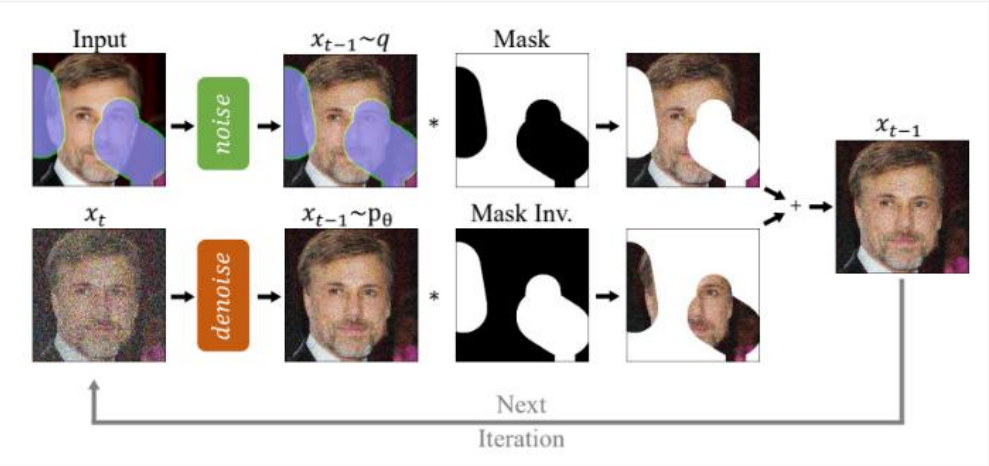

图 3.2　扩散模型图像修复示意图

(1)逆向扩散中的掩码约束：

在传统扩散模型中，去噪过程按照公式(3.5)执行。但在图像修复任务中，仅需要对掩码区域进行去噪，而保持未受损区域不变。因此，Lugmayr 等人提出了如下的修正策略：

$$x_{t-1} = m \bullet x_{t-1}^{known} + (1-m) \bullet x_{t-1}^{unknown} \tag{3.6}$$

公式(3.6)中，m 为二值掩码，表示修复区域。这一公式确保了未受损区域保持不变，仅对 Mask 区域进行预测，使得修复结果更加自然。

(2)采样策略优化：

Lugmayr 提出的 RePaint 方法不仅在掩码区域进行扩散，还引入了一种时间跳跃采样策略来提高修复质量，如图 3.2 所示。具体地，在去噪过程中，定期回溯到较高噪声状态，并重新去噪以增强模型的修复能力。这一策略使得被修复区域的多样性增加，避免简单的插值效果，提高最终图像的真实感。其中，在前向扩散过程中将掩码区域的像素随机扰动，使其与噪声匹配，在反向扩散中先进行标准去噪步骤。每隔 k 步，回溯到更高噪声步骤，再次执行去噪，这一过程持续进行，直至最终得到修复图像。图 3.3 展示了不同次数的重采样对图像协调性的影响。

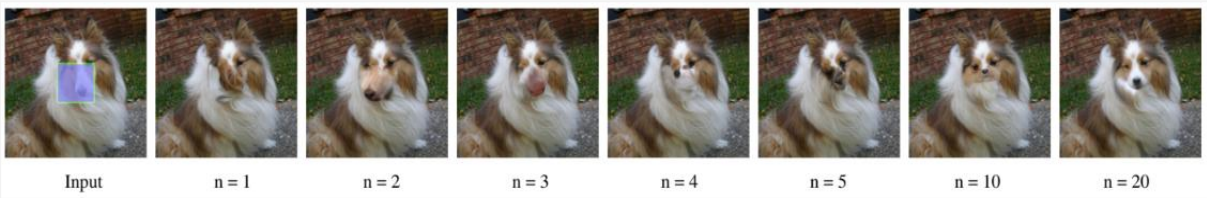

图 3.3　重采样次数对协调性的影响示意图

3.2　Stable-Diffusion-XL 用于图像修复

Stable-Diffusion-XL(SDXL)是 Stable-Diffusion 的增强版本，具备更强的文本理解能力、更大的潜在空间表达能力，并能够在高分辨率图像上生成更精细的内容。SDXL 在图像修复(Inpainting)任务中，利用掩码约束(Mask Conditioning)、双文本编码器(Dual Text Encoder)、潜在空间修复(Latent Space Inpainting)等关键技术，实现精准、高质量的修复效果。

3.2.1　Stable-Diffusion 基本原理

Stable Diffusion (SD) 是一种基于潜在扩散模型(Latent Diffusion Model,LDM)的图像生成技术。相较于直接在像素空间执行扩散，Stable Diffusion 在潜在空间(Latent Space)中执行扩散和去噪，使得计算成本大幅降低，同时保持高质量的图像生成能力。

SD 主要由三个核心模块组成，即 VAE 编码器/解码器、U-Net 去噪网络、文本编码

器(Text Encoder)。

SD 首先使用 VAE 编码器 $E(x)$ 将输入图像 x 映射到潜在空间：

$$z_0 = E(x) \tag{3.7}$$

其中，z_0 是潜在空间中的隐变量。由于潜在空间的维度远小于像素空间，计算效率得到提升。

然后，通过文本编码器生成文本嵌入 c 作为 U-Net 的输入：

$$c = TextEncoder(y) \tag{3.8}$$

接着，在潜在空间中执行扩散去噪(Denoising Diffusion)过程：

$$q(z_t|z_{t-1}) = \mathrm{N}(z_t; \sqrt{1-\beta_t} z_{t-1}, \beta_t I) \tag{3.9}$$

并通过 U-Net 预测噪声：

$$\hat{\varepsilon}_\theta = U(z_t, t, c) \tag{3.10}$$

通过逐步去噪，可以从噪声 $\hat{\varepsilon}_\theta$ 恢复出潜在表示 z_0。

最后，将去噪后的潜在变量 z_0 通过 VAE 解码器 $D(x)$ 变换回像素空间，生成最终图像:

$$\hat{x} = D(z_0) \tag{3.11}$$

3.2.2 基于 SDXL 的图像修复任务微调

Dustin Podel[12]等人在《SDXL:Improving Latent Diffusion Models for High-Resolution Image Synthesis》进一步提出 SDXL 模型，相比于 SD 采用扩大 3 倍的 U-Net，其中添加了更多的注意力块，提升了生成图像的细节质量，并采用了异构 Transformer 结构提高计算效率，去除了 8×降采样层，进一步优化了高分辨率图像的生成质量。

特别地，SDXL 在文本引导(Text-to-Image)方面有重要改进，通过采用双文本编码器(Dual Text Encoder)CLIP ViT-L/14 和 OpenCLIP ViT-bigG 增强文本理解能力，并使用更大的上下文维度使其能更精准地理解复杂文本描述。

此外，SDXL 优化了 VAE 结构，提高了细节保留能力以获得更好的潜在空间表示，在机制方面，SDXL 采用双阶段图像生成(Refinement Model)，如图 3.4 所示，在第一阶段使用基础模型(Base Model)生成 128×128 潜在变量(Latents)，然后放大到 1024×1024。在第二阶段使用一个专门的精细化模型(Refinement Model)进一步增强质量，该模型对初步生成的图像进行 额外的去噪-重建处理(SDEdit)，使得最终的图像更加清晰、纹理更加真实。

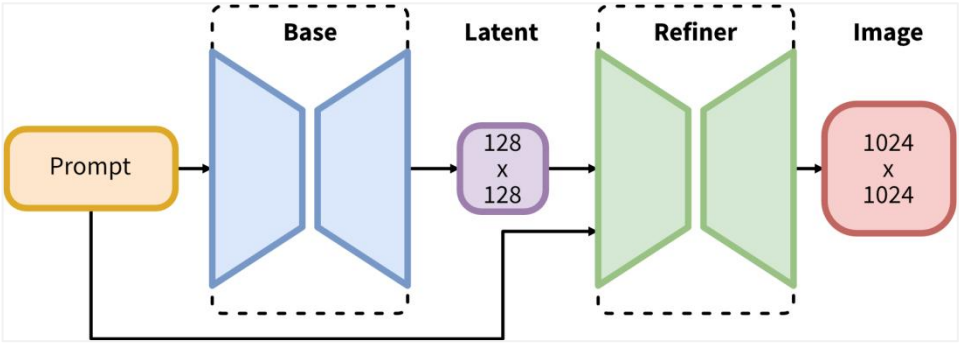

图 3.4　双阶段图像生成示意图

特别地，对于文本引导图像修复任务，输入数据为原图 image、掩码 mask、掩码混合图 masked_image 以及文本提示 prompt。

在本文的微调任务中，采用双文本编码器对提示词进行编码嵌入，生成文本 c 作为 U-Net 的输入：

$$c = (TextEncoder_1(y), TextEncoder_2(y)) \tag{3.12}$$

对于 image 与 masked_image，通过 VAE 编码器，将其转化为潜在空间表示：

$$z_{image} = E(x_{image}), z_{masked_image} = E(x_{masked_image}) \tag{3.13}$$

通过 VAE 编码器的潜在空间过程，将 image 和 masked_image 从 3 通道转化为 4 通道，再与 mask 拼接得到 9 通道的 U-Net 输入。

接着，对 mask 区域执行加噪过程，未被 mask 覆盖区域直接从原图取值：

$$z_t = \sqrt{\overline{\alpha}_t} z_{image} + \sqrt{1-\overline{\alpha}_t} z_{masked_image} \tag{3.14}$$

此外，还通过计算原始图像尺寸、裁剪坐标和目标尺寸，生成 time_ids 作为 U-Net 输入，通过这种方式，使 SDXL 在去噪过程中能够保持空间一致性，避免修复区域与周围像素不匹配：

$$time_ids = [H_{image}, W_{image}, y_1, x_1, H_{crop}, W_{crop}] \tag{3.15}$$

然后结合文本嵌入 c 与 time_ids 作为条件，引导 U-Net 预测去噪：

$$\hat{\varepsilon}_\theta = U(z_t, t, c, time_ids) \tag{3.16}$$

最终，逐步去噪，恢复干净的潜在表示 z_0，通过 VAE 解码器解码，生成最终修复后的图像：

$$z_0 = (z_t - \sqrt{1-\overline{\alpha}_t}\hat{\varepsilon}_\theta) / \sqrt{\overline{\alpha}_t} \tag{3.17}$$

$$\hat{x} = D(z_0) \tag{3.18}$$

3.3　系统框架图

图 3.5 展示了本文提出的图像修复系统整体框架，整体模型基于 SDXL。首先，原图像、待修复图像以及对应的遮码被分别输入至 VAE 编码器进行特征提取，将图像信

息编码至潜在空间。随后，三部分编码后的潜在空间特征被拼接融合，作为后续网络输入的重要组成部分。同时，对文本提示进行分词处理，并通过文本编码器获得文本嵌入特征，这些特征也被作为条件信息送入 U-Net 网络。此外，模型还通过去噪时间步模块提供时间步长信息，以进一步增强网络对于空间位置信息的感知能力。

拼接融合后的特征通过逐步去噪方式输入 U-Net 网络中进行特征提取与去噪处理，输出潜在空间中的修复图像特征。最后，经过 VAE 解码器将潜在空间特征映射回图像空间，生成最终修复后的图像。

本流程充分利用了潜在空间的特征表达能力，结合文本提示及空间位置信息，有效提高了图像修复结果的细节准确性和语义一致性。

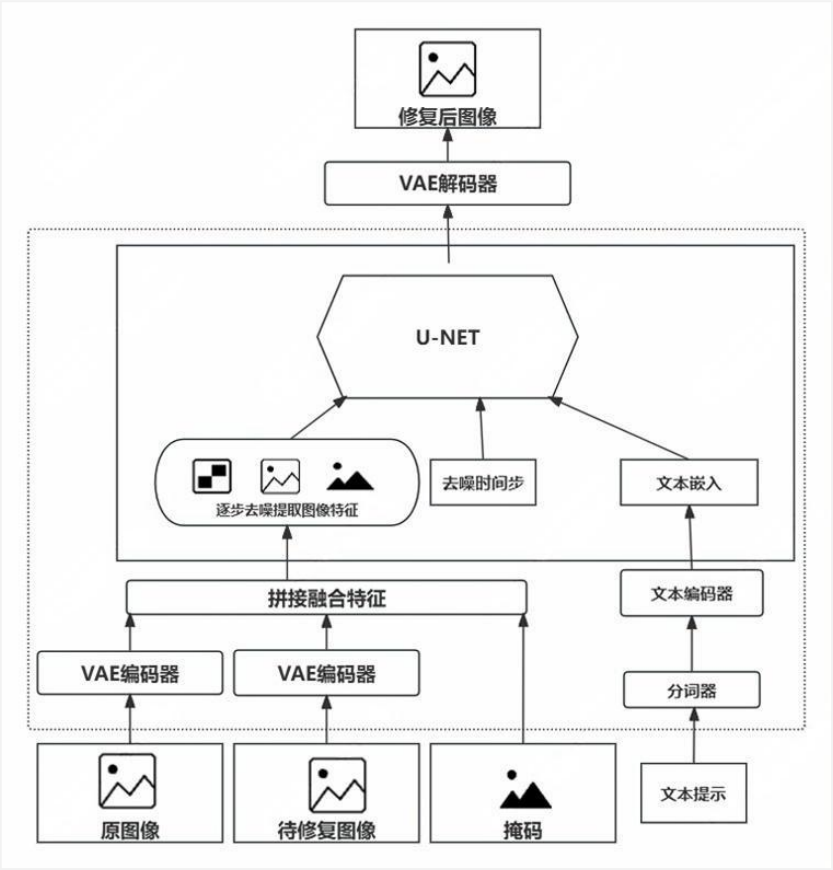

图 3.5　系统框架图

4 实验与分析

在实验之前，第 1 节中介绍实验数据集与计算环境，第 2 节中将介绍本实验用于评估的规则与方法。在第 3 节中，与其他现有模型进行对比，分析优劣性。在第 4 节中，设计对比实验，通过不同的微调参数设置，例如学习率、预热步数、学习率调度器、SNR 信噪比、权重衰减系数等，进行结果对比。最后在第 5 节中针对结果进行定性分析，结合数据集特点找到问题产生的原因。

4.1 数据集与计算环境

4.1.1 数据集

本文数据集将采用 MSCOCO2017[19]和 Brvcket[20]数据集。其中，MSCOCO 是微软开发维护的大型图像数据集，主要用于目标检测、分割、图像字幕生成等任务，具有 160000 余张图片，其除了包含训练集、验证集、测试集外，还包含了标注信息，每张图像都标注了多个目标的边界框和类别标签，如图 4.1 所示，支持 80 个类别，可进一步处理生成本文所需的掩码。

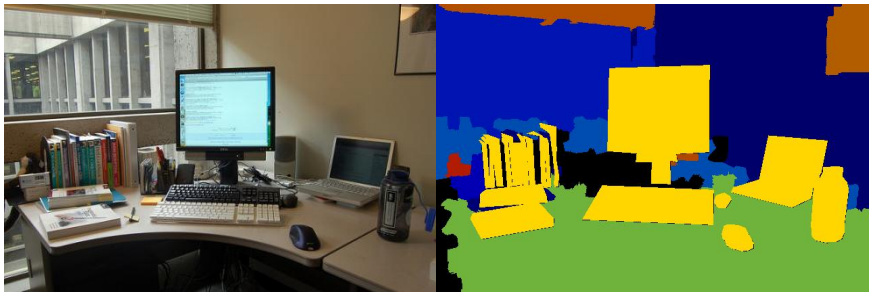

(a) 原图　　(b) 边界框图

图 4.1　MSCOCO 数据集

而 Brvcket 数据集则是 HuggingFace 社区的开源数据集，如图 4.2 所示，其直接包含本文任务所需的原图像、掩码图、掩码混合图及对应文本提示，是一个专门用于图像修复任务的数据集。

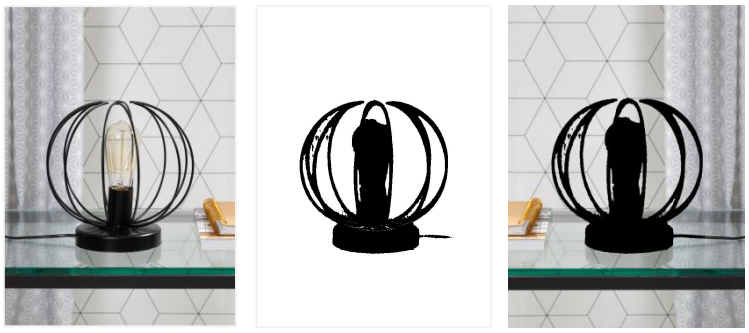

(a) 原图　　(b) 掩码　　(c) 掩码图

图 4.2　Brvcket 数据集

4.1.2 数据预处理

对于 MSCOCO 数据集，由于其没有直接包含二值掩码，需对其进行手动掩码分割，如图 4.3，根据其提供的分割实例，构造二值掩码图 mask, 并利用生成的 mask，将 mask 与原图进行合成，得到 masked image。这样，模型可以在输入中同时获得完整图像、mask 和 masked image，便于定位和修复缺失区域。

(a) 原图　　(b) 掩码　　(c) 掩码图

图 4.3　数据预处理示例

在处理完 MSCOCO 数据集，得到 image、mask、masked_image 后，进一步进行数据预处理，记录原始图像尺寸，用于后续计算 time_ids；再对所有图像进行统一重塑大小，设置为指定训练尺寸，在本文中，为了便于训练，设置像素为 768*768；后进行数据增强，将 image、mask、masked_image 进行水平反转、中心裁剪，记录起始坐标，用于计算 time_ids；再将图像数据进行归一化，其中均值为 0.5，标准差为 0.5，使像素分布在[-1,1]，并将其转为 tensor，其中 mask 不做归一化，保留其像素值的二值形式，用于指示待修复区域。

对于文本也需进行预处理，具体地，由于 SDXL 采用双文本编码器，分别调用预训练的两个分词器生成两个不同的文本 token ID 用于后续输入模型 。

本文通过引入 time_ids 额外空间信息，帮助模型再修复时更好地理解当前 patch 在整体图像中的位置，从而生成更协调的修复结果，具体地，将原始图像尺寸、裁剪起始坐标和目标尺寸按顺序拼接成一个 6 元素的列表输入给模型。

此外，为了确保输入数据适配潜在扩散模型(Latent Diffusion Model,LDM)的训练范式，原始图像需首先转换至潜在空间(Latent Space)，随后通过随机时间步(Timesteps)注入噪声，以构建模型的学习目标。本节详细描述该转换过程，包括潜在编码(LatentEncoding)和噪声添加(Noise Injection)两个关键步骤。

(1)潜在空间转换(Latent Encoding)

给定原始图像 $x \in R^{H \times W \times C}$，首先利用预训练的变分自编码器(Variational Autoencoder,VAE)将其映射至潜在空间。该过程可表示为：

$$z = \mathrm{E}(x) \cdot s \tag{4.1}$$

其中，E( )表示 VAE 编码器(Encoder)，s 为 VAE 的缩放因子(Scaling Factor)，用于对潜在变量进行归一化以适应 LDM 训练过程。VAE 编码的输出 $z \in R^{h \times w \times d}$ 其中 h=H/f, w=W/f，d 为潜在空间的通道数，f 为 VAE 下采样因子(通常为 8)，此外，为适应图像修复任务，对掩码混合图 masked_image 也进行相同 VAE 编码，得到其对应的潜在表示：

$$z_{masked_image} = E(x_{masked_image}) \cdot s \tag{4.2}$$

同时，掩膜图像 m 经过相同的空间变换，使其尺寸匹配潜在空间中的 z_{masked_image}。最终，形成联合输入：

$$Z = concat(z, z_{masked_iamge}, m) \tag{4.3}$$

其中，$Z \in R^{\mathrm{h} \times w \times 2d+1}$ 作为扩散模型的输入通道。

(2) 噪声添加(Noise Injection)

扩散模型训练的目标是学习去噪过程，因此需在潜在空间上构造不同噪声水平的训练样本。首先，从标准正态分布中随机采样噪声：

$$\theta \sim \mathrm{N}(0, I) \tag{4.4}$$

若设定噪声偏移(Noise Offset)，则噪声表达式进一步调整为：

$$\theta' = \theta + \alpha \cdot \mathrm{N}(0, I) \tag{4.5}$$

其中，α 为超参数，控制额外噪声的强度。随后，随机选择扩散过程中的时间步 t：

$$t \sim U\{0, T\} \tag{4.6}$$

并根据调度器(Noise Scheduler)计算该时间步对应的噪声权重 σ_t，最终对潜在变量添加噪声：

$$Z_t = Z + \sigma_t \theta' \tag{4.7}$$

得到的 Z_t 作为神经网络的输入，其目标是预测加入的噪声 θ'，从而学会逐步去噪，恢复原始潜在表示 Z。

4.1.3 计算环境

本文实验部分的计算环境使用了阿里云计算，其中镜像配置为，操作系统采用阿里云 ubantu22.04，CPU 为 8vCPU，GPU 为 NVIDIA V100 24GB，内存大小为 32GB，虚拟环境为 cuda12.1.0-py310-torch2.3.1

4.2 实验评估方法

在图像修复(Inpainting)任务中，常用的评价指标可以分为像素级指标、感知质量指标和语义匹配指标。不同的指标关注图像修复的不同方面，包括像素恢复精度、视觉质量以及与原始语义的匹配程度。

像素级指标主要有均方误差(Mean Squared Error,MSE)和峰值信噪比(Peak Signal-to-Noise Ratio,PSNR)，在本文中采用 MSE 作为像素级评价修复的指标，其计算公式为：

$$MSE = 1/N \sum_{i=1}^{N} (I_{gt,i} - I_{pred,i})^2 \tag{4.8}$$

公式中，I_{pred} 是修复图像，I_{gt} 是原始图像。MSE 值越低，表示修复图像越接近原始图像。但 MSE 不能反映视觉感知质量，可能导致过度平滑的结果。

感知质量指标主要有结构相似性指数(Structural Similarity Index,SSIM)和可学习感知图像块相似度(Learned Perceptual Image Patch Similarity,LPIPS)，在本文中采用 LPIPS 作为感知质量评价指标，其公式为:

$$LPIPS = \sum_l \omega_l \left\| F_l(I_{gt}) - F_l(I_{pred}) \right\|_2^2 \tag{4.9}$$

其中，$F_l(x)$，$F_l(y)$ 分别表示 第 l 层的特征映射，即利用深度神经网络(如 VGG、AlexNet)在第 l 层提取的图像特征。ω_l 是通道归一化的权重，用于调整不同层的感知贡献，使得低层(捕捉局部细节)和高层(捕捉语义信息)特征在计算感知相似性时具有合适的权重。LPIPS 值越小，表示两幅图像在感知上越相似。

语义匹配指标主要有弗雷歇特距离(Frechet Inception Distance,FID)和图文匹配得分(CLIP Score)，在本文中都将进行采用，其中 FID 用于衡量修复后的图像在视觉上的真实性和整体视觉一致性。计算修复后图像与真实图像的分布差异，使用 Inception v3 作为特征提取器，计算两者特征分布的 Frechet 距离。数值越低，表示修复效果越好。CLIP Score 则评估修复后的图像与输入的文本提示(Text Prompt)之间的语义一致性(Semantic Relevance)。即计算修复后图像的 CLIP 特征向量与文本特征向量的余弦相似度。数值越高，表示生成的对象与文本描述的匹配度越好。

4.3 实验结果分析

为了证明模型 SDXL 的有效性，将本文采用的方法与 GAN、VAE 模型在数据集 MSCOCO 上进行比较，通过定性和定量分析以直接看出所提出方法的有效性。

(1) 定量比较

为了更好地对比所提出的算法与其他修复算法的有效性，使用均方误差(Mean Squared Error,MSE)、可学习感知图像块相似度（Learned Perceptual Image Patch Similarity, LPIPS）、弗雷歇特距离(Frechet Inception Distance,FID)和图文匹配得分(CLIP Score)4 种损失进行定量比较，结果如表 4.1 所示。

表 4.1　不同方法在 MSCOCO 数据集上的定量比较结果

指标	掩码比例	GAN	VAE	本文方法
MSE ↓	10%~15%	0.012	0.016	**0.009**
	15%~20%	**0.017**	0.021	**0.017**
	20%~25%	0.025	0.031	**0.020**
	25%~30%	0.033	0.042	**0.025**
LPSIPS ↓	10%~15%	0.15	0.18	**0.10**
	15%~20%	0.21	0.25	**0.13**
	20%~25%	**0.26**	0.33	0.27
	25%~30%	0.34	0.41	**0.22**
FID ↓	10%~15%	12.6	17.8	**6.0**
	15%~20%	**18.2**	23.7	19.0
	20%~25%	25.3	30.1	**10.4**
	25%~30%	31.6	37.9	**13.2**
CLIP Score ↑	10%~15%	0.81	0.76	**0.88**
	15%~20%	0.78	0.72	**0.86**
	20%~25%	0.74	0.68	**0.84**
	25%~30%	0.70	0.64	**0.81**

在 MSCOCO 数据集上，在不同的掩码比例范围下，将本文采用的方法与 GAN、VAE 进行了定量比较，见表 4.1，其中“↑”代表数值越大效果越好，“↓”代表数值越小效果越好，在掩码比例较小时，各方法在指标表现上相对接近，均能实现较为合理的图像重建效果。例如在掩码比例为 10%~15%时，GAN 的 MSE 为 0.012，VAE 为 0.016，本文方法为 0.009；LPIPS 分别为 0.15、0.18 和 0.10；FID 为 12.6、17.8 和 6.0，说明即便在低遮挡场景下，本文方法仍具备一定优势。

随着掩码比例的增加，各算法在不同指标上的差距逐渐扩大。特别是在掩码比例为 20%~25%和 25%~30%区间，VAE 的 MSE 分别上升至 0.031 和 0.042，而本文方法分别为 0.020 和 0.025，始终低于 GAN 和 VAE。与此同时，本文方法在 LPIPS 和 FID 指标上也保持较低数值，展现出更强的感知一致性与分布拟合能力。例如在最大遮挡比例（25%~30%）下，本文方法的 LPIPS 和 FID 分别为 0.22 和 13.2，明显优于 GAN（0.34,31.6）和 VAE（0.41,37.9）。

此外，在反映图像语义一致性的 CLIP Score 指标中，本文方法在所有掩码比例下均取得最高得分，且随着掩码比例增加，其优势愈加明显。例如在掩码比例为 25%~30%

时，GAN 和 VAE 的 CLIP Score 分别为 0.70 和 0.64，而本文方法仍能达到 0.81，说明其生成结果在语义层面更贴近原始图像。

综上所述，本文方法在各个掩码比例范围内，在大多数评估指标上均取得了更优的重建效果，特别是在掩码比例较高的情况下性能优势更加显著。这表明本文方法在处理大范围缺失区域时具备更强的重建能力与语义保持能力，展现出更高的鲁棒性和实用性。

(2) 定性比较

为了定型比较本文采用的 SDXL 模型的与 GAN、VAE 的修复效果，本小节在 MSCOCO 数据集上进行比较，如图 4.4 所示。从左至右依次为原始图像、掩码图、VAE 修复结果、GAN 修复结果、本文方法修复结果。VAE 方法生成的图像普遍在语义上存在偏差，细节信息处理较为模糊，边缘过渡不自然；GAN 方法在一定程度上提升了图像的清晰度，但语义一致性仍有待提高，尤其在较大缺失区域中，生成结果的语义特征还原程度不高。相比之下，本文方法在整体结构一致性、纹理细节还原以及语义合理性方面均表现出明显优势。这说明本文方法不仅具有较强的图像先验建模能力，同时也具备更优的上下文理解与生成能力。综上，本文提出的方法展现出更高的重建质量和视觉一致性，定性实验结果进一步验证了其在复杂场景中处理大面积缺失区域的有效性和鲁棒性。

(a)原图　(b)掩码图　(c)VAE　(d)GAN　(e)本文方法

图 4.4　不同算法修复效果对比图

4.4 微调参数对比实验

为进一步比较不同的微调参数对模型修复效果的影响，本小节将尝试改变不同训练参数来对比 SDXL 模型在 Brvcket 数据集上的修复效果。

首先，从 Huggingface-stable-diffusion-v1-5 获取的 SDXL 预训练权重通过 git 配置到阿里云实例，按照表 4.2 进行配置。

表 4.2 环境依赖一览表

库	版本
diffusers	0.33.0dev
torch	2.6.0
transformers	4.49.0
datasets	3.3.2
accelerate	1.4.0
peft	0.14.0
tqdm	4.65.0
cuda	11.8

本小节将通过调整以下训练参数，在 Brvcket 数据集上对 SDXL 预训练模型进行 LoRA 微调，并分别对比不同参数下模型的修复效果。参数见表 4.3、4.4、4.5 训练参数配置表。

表 4.3 训练超参数配置表

名称	说明
seed	随机种子，用于结果可重复性
train_batch_size	每个设备上的训练批量大小
num_train_epochs	总训练周期数
gradient_accumulation_steps	累积梯度的步数，达到一定步数后再进行参数更新。
learning_rate	初始学习率
rank	低秩分解中低秩矩阵的维度
lora_alpha	LoRA(低秩适应)中的一个超参数，用于缩放低秩更新矩阵的贡献
lr_scheduler	学习率调度器类型
lr_warmup_steps	学习率预热步数
adam_beta1、adam_beta2	Adam 优化器的 beta 参数

续表 4.3　训练超参数配置表

名称	说明
adam_weight_decay	权重衰减系数
snr_gamma	用于损失重平衡的 SNR 权重 ，用来控制对各个时间步损失的重新加权，帮助模型更均衡地学习去噪和图像修复任务
adam_epsilon	Adam 优化器中的 epsilon 值
max_grad_norm	梯度裁剪的最大范数
dataloader_num_workers	数据加载时使用的子进程数

表 4.4　模型与数据相关参数配置表

名称	说明
pretrained_model_name_or_path	预训练模型的路径或 Hugging Face 上的标识
dataset_name	数据集名称，可以使用 Hugging Face Hub 上的公开数据集或自定义数据集
dataset_config_name	数据集配置
resolution	输入图像的分辨率，训练前所有图像都会被调整到该尺寸
center_crop	是否采用中心裁剪(开启则采用中心裁剪，否则随机裁剪)
random_flip	是否对图像进行随机水平翻转

表 4.5　验证与输出相关参数表

名称	说明
validation_prompt	用于验证生成图像的提示文本
num_validation_images	每次验证生成的图像数量
validation_epochs	每隔多少个 epoch 进行一次验证
resolution	保存模型、检查点及日志的输出目录
cache_dir	模型和数据集下载的缓存目录

在本文实验中，设置训练参数见表 4.6 作为 baseline，后续实验通过改变 baseline 中

的部分的参数以对比修复效果。其中，数据集采用 Brvcket 数据集，图像分辨率为 768*768，考虑到训练集包含的庞大数据量，设置周期为 10，学习率保持 5e-6 不变，LoRA 低秩分解矩阵维度 rank 为 4，低秩适应参数与矩阵维度保持一致，同为 4。

表 4.6　baseline 参数表

名称	取值
resolution	768
train_batch_size	2
num_train_epochs	10
rank	4
lora_alpha	4
lr_scheduler	"constant"
lr_warmup_steps	None
learning_rate	5e-6
adam_weight_decay	1e-2

(1)Baseline

经过在 Brvcket 数据集上进行 10k 次迭代，训练中的损失函数如图 4.5(a)所示，损失函数在前期下降明显，训练过程也比较稳定，逐步减少趋于收敛，修复效果如图 4.6(c)所示,文本提示统一为“Crystal lamps”。

(2)Cosine 型

学习率调度器 lr_scheduler 采用 cosine，余弦衰减从初始值下降到接近零。这种方式能提供平滑的衰减曲线，有助于在训练后期保持较低的更新幅度，通常有助于模型收敛到更好的局部最优，其余参数选择默认值，经过在 Brvcket 数据集上进行 10k 次迭代，训练中的损失函数如图 4.5(b)所示，损失函数在前期下降明显，训练过程出现跳动，在训练后期逐步减少趋于收敛，修复效果如图 4.6(d)所示。

(3)Rank8 型

低秩分解的矩阵维度 rank 为设置为 8，并且将 lora_alpha 设置为 8，其余参数选择默认值。rank 越大，低秩矩阵的容量就越高，模型可以通过 LoRA 学到更多的新任务特定信息，但同时也会增加训练参数量和过拟合风险。对应地，lora_alpha 较大，低秩更新部分对模型输出的影响就会更强。这样在微调时，模型会更大幅度地偏离预训练权重，以适应新任务。经过在 Brvcket 数据集上进行 10k 次迭代，训练中的损失函数如图 4.5(c)所示，损失函数在前期下降明显，训练过程出现略微跳动，总体损失函数小于前两种情况，并在后期有着明显下降趋势,修复效果如图 4.6(e)所示。

(4)Warm-up 型

学习率预热步数 lr_warmup_steps 设为 500，其余参数选择默认值。先进行“预热”阶段，在这段时间内学习率从零(或一个非常低的值)逐渐线性上升到设定的常数值，之后保持恒定。Warm-up 阶段有助于在训练初期稳定参数更新，减少大梯度带来的不稳定风险。经过在 Brvcket 数据集上进行 10k 次迭代，训练中的损失函数如图 4.5(d)所示，损失函数始终处于稳定下降趋势，使得训练过程非常稳定，但仅在较少迭代次数内，损失函数下降速度较慢，修复效果如图 4.6(f)所示。

(5)Linear 型

学习率调度器 lr_scheduler 采用线性衰减型 linear，其余参数选择默认值。通过这种方式可使学习率线性衰减直至训练结束时降低到预设的最低值(通常为零)。这种方式简单直观，适用于训练过程中希望稳定地降低学习率的场景。经过在 Brvcket 数据集上进行 10k 次迭代，训练中的损失函数如图 4.5(e)所示，损失函数在训练过程中常有起伏，但其数值总体下降较快，在各方法中处于最佳情况，并且各修复指标优于其他情况，修复效果如图 4.6(g)所示。

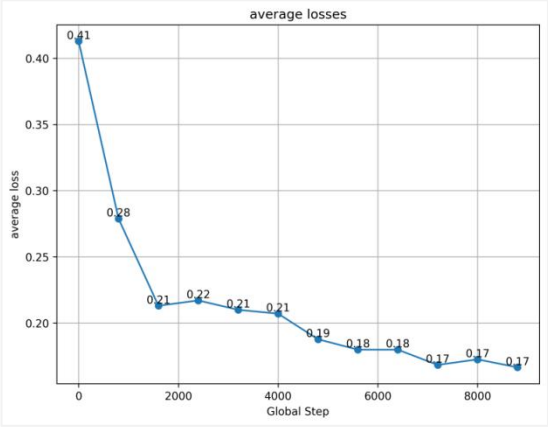

(a) Baseline 型

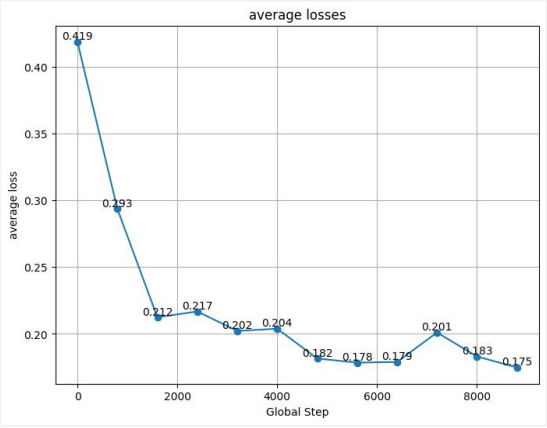

(b) Cosine 型

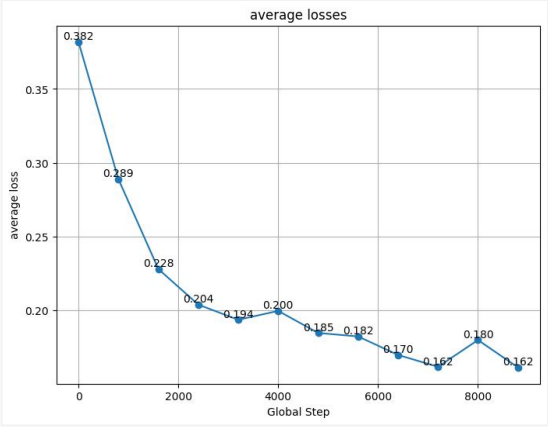

(c) Rank8 型

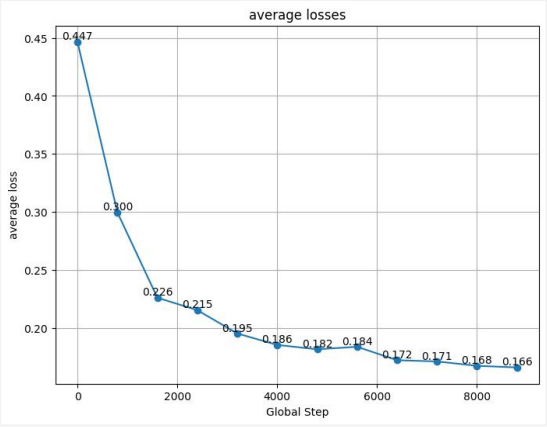

(d) Warmup 型

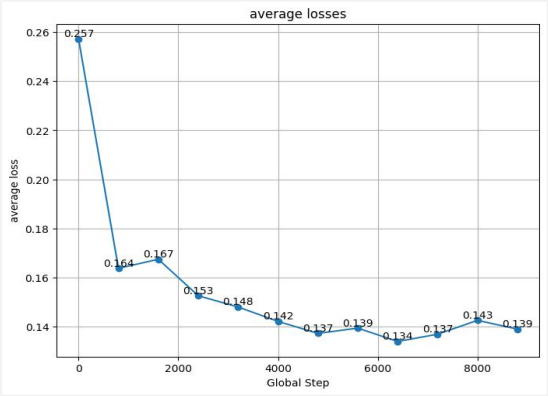

(e) Linear 型

图 4.5 训练损失函数图

(a) 原图 (b) 掩码图 (c) Baseline 型

(d) Cosine 型 (e) Rank8 型

(f) Warmup 型 (g) Linear 型

图 4.6 修复效果一览图

各参数组合及其效果见表 4.7 和图 4.7，从结果来看，不同参数设置对图像修复的最终性能确实产生了明显影响。

表 4.7　微调参数结果对比表

指标	Baseline	Cosine	Rank8	Warm-up	Linear
MSE ↓	0.017	0.015	0.025	0.016	0.017
LPIPS ↓	0.154	0.17	0.184	0.165	0.171
FID ↓	16.773	15.898	17.462	16.336	15.476
CLIP Score ↑	0.826	0.857	0.842	0.877	0.869

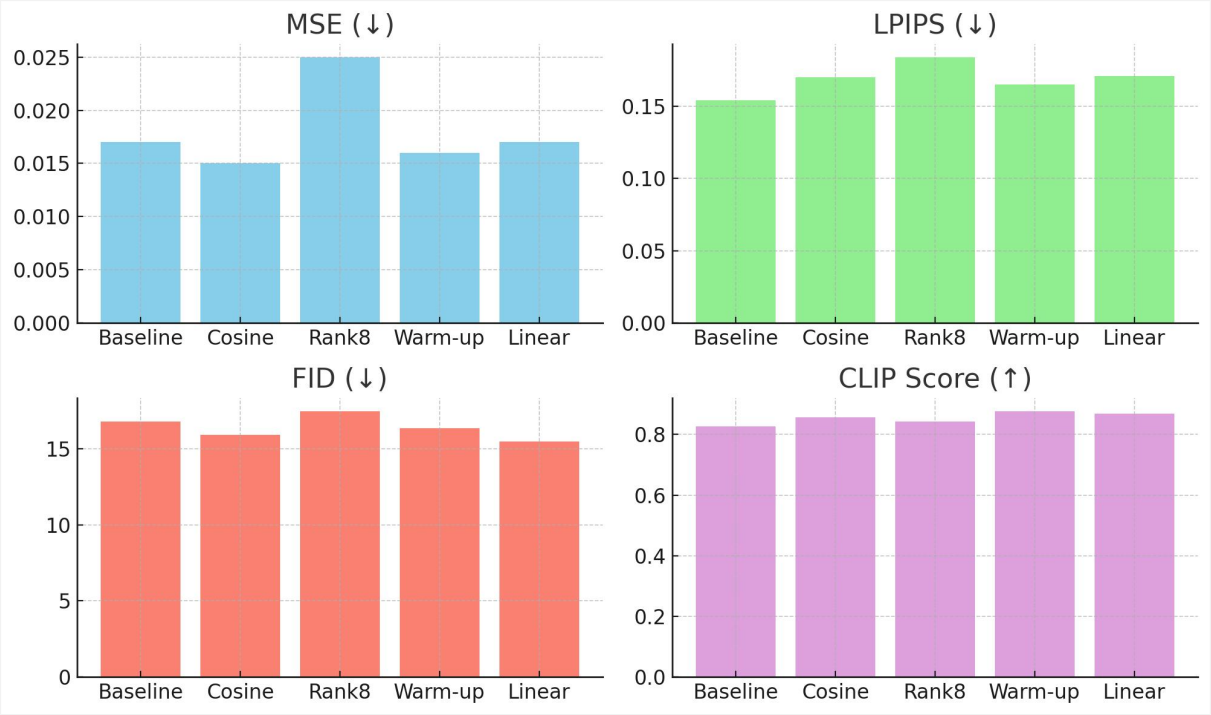

图 4.7　微调参数效果对比图

图 4.7 中，MSE、LPIPS、FID 值越小代表修复效果越好，CLIP Score 越大代表修复效果越好。在默认参数设定(baseline)下，模型表现较为平衡，MSE 为 0.017，LPIPS 为 0.154，FID 为 16.773，CLIP Score 为 0.826，训练过程较稳定，为后续对比提供了良好的参考。

引入 cosine 学习率调度后，模型在 FID（15.898）和 CLIP Score（0.857）上略有提升，说明余弦式衰减有助于提升语义一致性和生成图像分布的合理性，但 LPIPS 相较 baseline 略有上升（为 0.170），可能在感知一致性方面存在轻微牺牲。

在 rank8 设置中，通过提升 LoRA 的容量增强模型学习能力，虽然训练损失整体下降趋势良好，但修复结果反而出现退化，MSE 升高至 0.025，FID 上升至 17.462，说明

过高的参数自由度可能导致过拟合，破坏了模型在复杂缺失区域中的泛化能力。

在 warm-up 设置下，虽然 MSE 和 LPIPS 未达到最优（分别为 0.016 和 0.165），但 CLIP Score 达到最高（0.877），显示 warm-up 有助于模型更充分学习提示词的语义信息；训练过程也相对平稳，适用于大规模训练或复杂场景下的微调。

采用 linear 学习率调度策略时，模型在各项指标中表现出最优的整体均衡性。在训练过程中损失下降快速，最终在 FID（15.476）和 CLIP Score（0.869）方面均表现突出，且感知指标 LPIPS（0.171）也在可接受范围之内，说明线性衰减机制能较好地兼顾稳定训练和性能优化。

综上所述，不同微调参数对模型的修复效果具有显著影响。其中，linear 学习率调度策略在综合指标上表现最优，而 warm-up 策略在语义一致性方面具有优势，cosine 策略适合中等训练周期，rank8 虽然提升模型容量但存在过拟合风险。该系列对比实验充分证明了参数选择对于模型泛化能力和修复效果的关键作用。

4.5 可视化分析

本节将基于章节 4.4 得到的最佳参数设定，见表 4.8，在 MSCOCO 上进行微调并观察修复效果，其中迭代步数约 20k 步，其训练损失函数见图 4.8。

表 4.8 MSCOCO 参数一览表

名称	取值
resolution	768
train_batch_size	2
num_train_epochs	5
rank	4
lora_alpha	4
lr_scheduler	"linear"
lr_warmup_steps	500
learning_rate	1e-4
adam_weight_decay	0.15

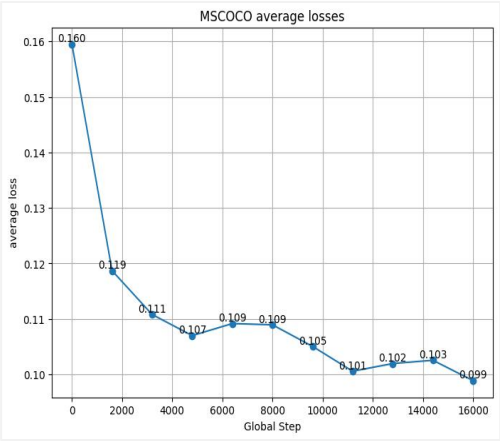

图 4.8　MSCOCO 训练损失函数图

经过约 20k 次迭代，该模型已能充分结合文本提示进行生成，其修复效果示例见图 4.9。

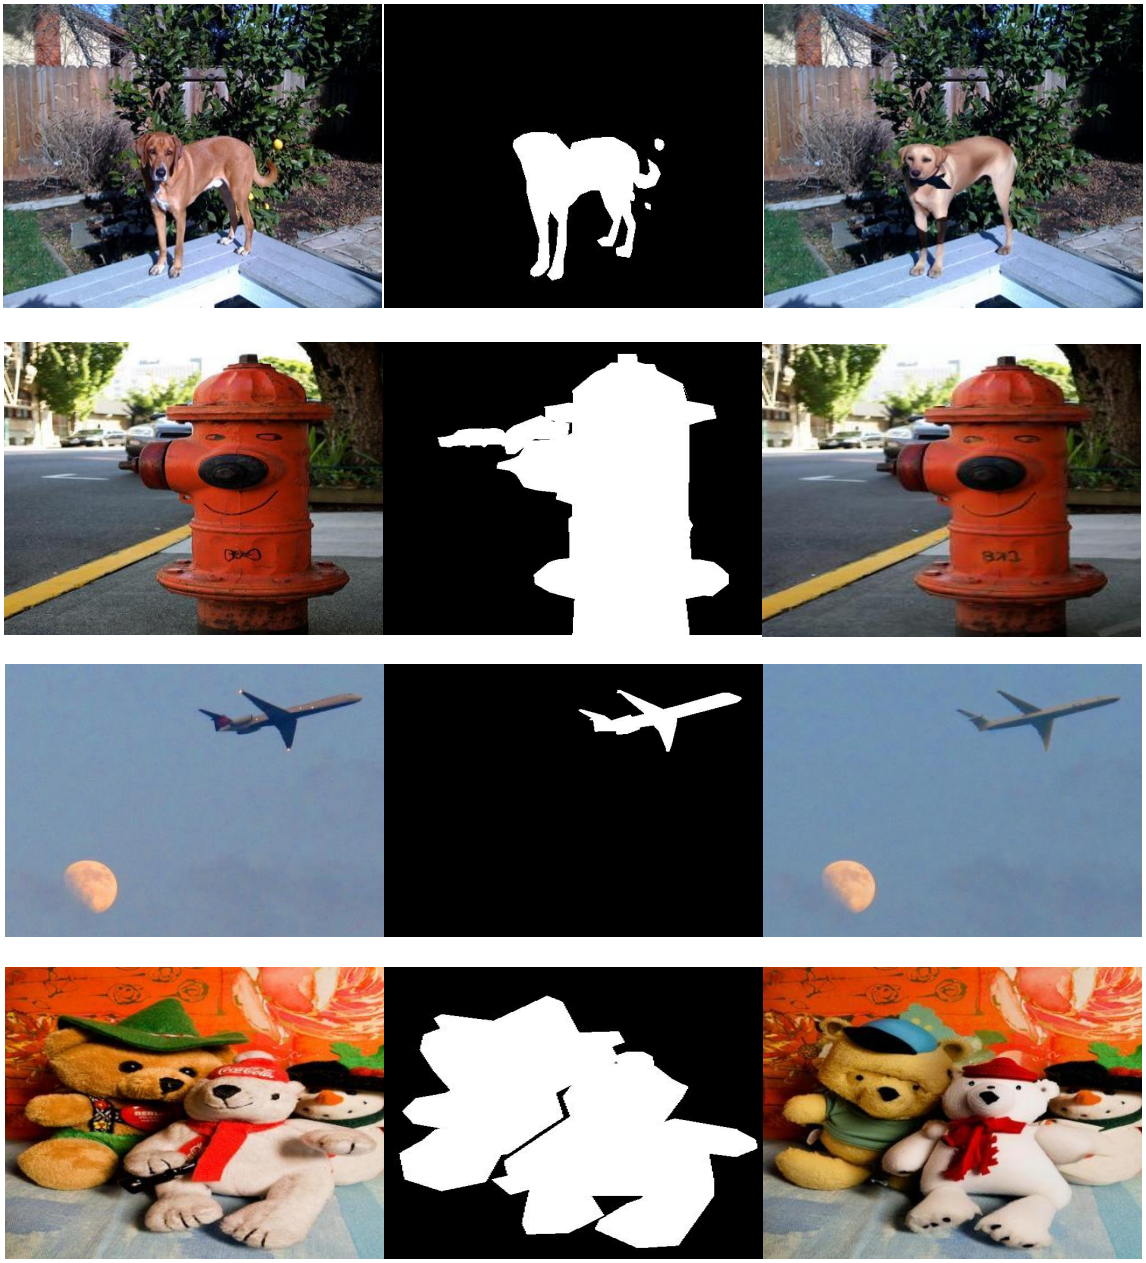

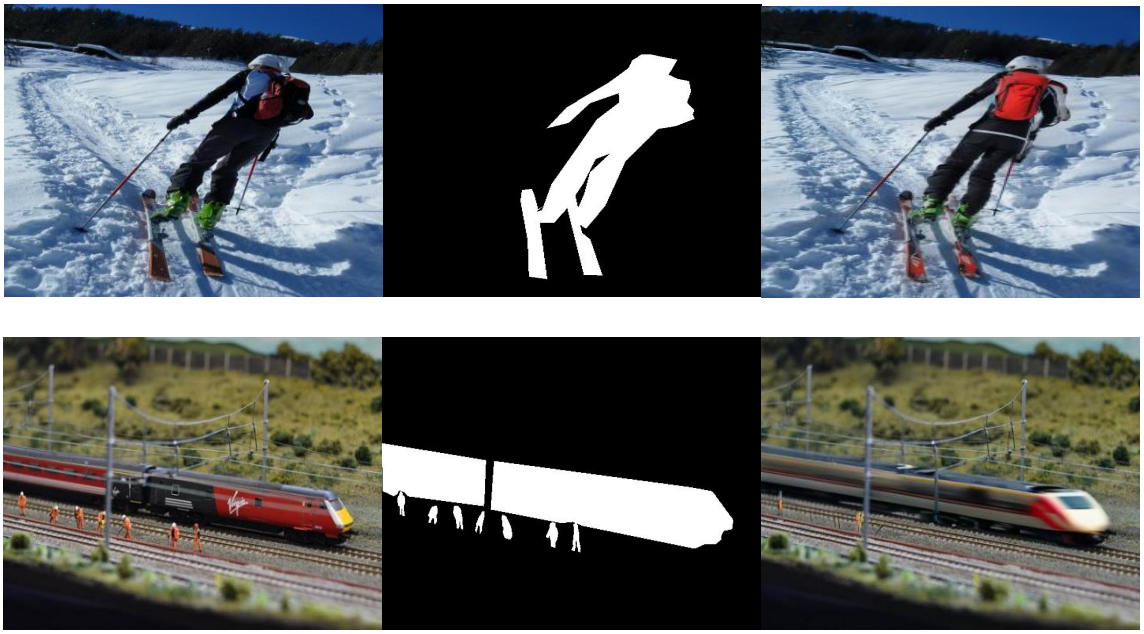

(a) 原图　　(b) 掩码图　　(c) 修复图

图 4.9　MSCOCO 修复效果一览

5 总结与展望

5.1 总结

图像修复是计算机视觉领域的研究热点，在文化遗产保护、影视娱乐、个人隐私保护、医学影像处理、艺术创作等方面具有广阔应用前景，而修复图像对语义、结构和纹理一致性的要求一直是极具挑战的课题。本文在预训练多模态大模型 Stable-Diffusion-XL 的基础上，在 MSCOCO、Brvcket 数据集上进行了文本引导的图像修复任务微调以更好适应特定的下游任务，现总结本文的工作如下：

(1) 模型输入调整：针对图像修复任务的特点，本文对预训练的 Stable-Diffusion-XL 模型进行了输入格式的调整。具体地，将原图、经过 mask 处理的图像以及 mask 自身在 VAE 编码后得到的潜在表示进行拼接，从而构造出 9 通道的 U-Net 输入，使模型能够在潜在空间中精准定位并恢复待修复区域。

(2) 文本引导与附加条件引入：利用双文本编码器生成文本嵌入，结合额外的时间标识(time_ids)，为模型提供语义与空间位置信息，从而更好地引导模型在修复过程中保持图像整体的协调性和语义一致性。

(3) 微调策略探索：本文在 Brvcket 和 MSCOCO 等数据集上进行了大量对比实验，探索了不同的微调参数(如学习率、预热步数、学习率调度器、LoRA 参数设置等)对修复效果的影响。实验结果表明，学习率线性衰减(linear)与预热步数(warmup)结合可使训练更加稳定，并且损失更小，可以显著提升模型在文本引导图像修复任务上的性能。

(4) 评价指标与定性分析：为全面评估模型性能，本文采用了多种指标，包括 MSE、LPIPS、FID、和 CLIP Score，并结合定性分析对比不同配置下的修复效果，验证了本文方法在细节恢复和语义一致性方面的优势。

总体来说，本文通过对预训练 SDXL 模型进行针对性的微调和创新改进，实现了文本引导下的高质量图像修复。实验结果表明，本文方法在不同数据集上均能较好地恢复图像缺失区域，同时在视觉感知和语义匹配方面取得了较优表现，为实际应用提供了一种高效、稳定的解决方案。

5.2 展望

尽管本文在文本引导图像修复任务上通过对预训练 SDXL 模型进行微调取得了一定成效，但在实际应用和进一步提升模型性能方面仍存在一些不足，未来的工作可以在以下几个方向展开改进：

(1)推理速度与计算效率：

扩散模型固有的计算复杂度较高，尤其在高分辨率图像修复中，推理速度较慢。未来工作可尝试采用模型剪枝、量化或知识蒸馏等技术，设计轻量化网络结构，降低模型

参数量和计算成本，从而实现更高效的推理与实时应用。

(2)跨域和复杂场景适应性：

当前模型主要在 Brvcket 和 MSCOCO 数据集上进行验证，未来需要探索模型在更多领域和复杂场景下的表现。可以考虑引入领域自适应技术以及无监督或半监督学习方法，进一步提升模型在不同数据分布下的鲁棒性和泛化能力。

(3)超参数敏感性与自动调优：

当前微调过程中，对学习率、预热步数、LoRA 参数等超参数较为敏感，不同参数组合对修复效果有显著影响。未来可以考虑引入自动化超参数搜索(如贝叶斯优化或进化算法)，从而获得更鲁棒的参数配置，减少人工调试成本，提高模型在不同任务下的泛化能力。

致 谢 –

转眼间大学时光已悄然消逝，仿佛昨天还在教室里听着高等数学，憧憬着大学生活。而今我也成为了老师们口中的往届学长，随着论文的逐步完成，我想我的大学生活应该也结束了，这一路实在感慨万分，在此也有一些话想对自己，对导师、对身边的同学说。

首先，我要衷心感谢我的指导老师。胡老师在整个研究过程中给予我细致入微的指导，从选题到实验、撰写，都倾注了大量心血。他严谨的治学精神、耐心的讲解以及鼓励性的指导意见，使我受益匪浅，并且帮助我顺利完成本课题的研究。此外，作为学校教师团体的新鲜血液，他为我们学生带来了新方法、新理论、新思想，我们可以不用禁锢于传统的落后于现代企业的技术，而是可以学习到受用于当代社会的新技术，这是十分难能可贵的，这种新理论帮助我更好地探索当今层出不穷的新方法，永远怀着一种开放的思想去接受新事物。

同时，也要感谢一路坚持下来的自己，面对迷茫时的自我激励，面对困难时的咬牙坚持，每一步的努力都记录着自己的成长与蜕变。未来的路依然漫长，但我相信，在过去几年积累的知识和经验指引下，我可以更自信、更勇敢地面对人生新的篇章。

最后，我要感谢身边的伙伴们，在大学生活中，你们是我记忆中不可磨灭的一部分，我们一起经历了许多压力、欢喜、悲伤，这些真挚的友情带给了我无尽的温暖与力量，让我深刻体会到团队协作的可贵与人际交往的重要性。未来无论我们身处何方，这份珍贵的回忆都将激励我不断前进。

再次感谢所有在我大学时光中帮助、陪伴和支持我的人们！

参考文献

[1] Gonzalez R. C., Woods R. E. Digital image processing[M]. 3rd ed. Upper Saddle River, NJ: Prentice Hall, 2008: pp. 1-954. ISBN: 9780131687288.

[2] Canny J. A computational approach to edge detection[J]. IEEE Transactions on Pat tern Analysis and Machine Intelligence, 1986: 8(6):679-698.

[3] Efros A. A., Leung T. K. Texture synthesis by non-parametric sampling[C]// Proce edings of the 7th IEEE International Conference on Computer Vision. IEEE, 1999: 1033-1038.

[4] Criminisi A., Pérez P., Toyama K. Region filling and object removal by exemplar-based image inpainting[J]. IEEE Transactions on Image Processing, 2004: 13(9):12 00-1212.

[5] Bertalmio M., Sapiro G., Caselles V., et al. Image inpainting[C]// Proceedings of t he 27th Annual Conference on Computer Graphics and Interactive Techniques. Ne w York: ACM, 2000: 417-424.

[6] Kingma D. P., Welling M. Auto-encoding variational Bayes[C]// International Conf erence on Learning Representations (ICLR), 2014: arXiv:1312.6114.

[7] Goodfellow I., Pouget-Abadie J., Mirza M., et al. Generative adversarial nets[C]// Advances in Neural Information Processing Systems, 2014: 2672-2680.

[8] Radford A., Metz L., Chintala S. Unsupervised representation learning with deep c onvolutional generative adversarial networks[J]. arXiv preprint, 2015: arXiv:1511.06 434.

[9] Mirza M., Osindero S. Conditional generative adversarial nets[J]. arXiv preprint, 2 014: arXiv:1411.1784.

[10] Arjovsky M., Chintala S., Bottou L. Wasserstein generative adversarial networks[C] // Proceedings of the 34th International Conference on Machine Learning (ICML), 2017: 214-223.

[11] Ho J., Jain A., Abbeel P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems, 2020: 6840-6851.

[12] Podell D., Blattmann A., Sarin S. SDXL: Improving latent diffusion models for hi gh-resolution image synthesis[J]. arXiv preprint, 2023: arXiv:2307.01952.

[13] Sohn K., Yan X., Lee H. Learning structured output representation using deep con ditional generative models[C]// Proceedings of the 28th International Conference on

Neural Information Processing Systems - Volume 2 (NIPS'15). MIT Press, Cambridge, MA, USA, 2015: 3483-3491.

[14] Higgins I., Matthey L., Pal A., et al. beta-VAE: Learning basic visual concepts with a constrained variational framework[C]// International Conference on Learning Representations (ICLR), 2017: arXiv:1606.05579.

[15] Isola P., Zhu J. Y., Zhou T., et al. Image-to-image translation with conditional adversarial networks[C]// Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017: 1125-1134.

[16] Zhu J. Y., Park T., Isola P., et al. Unpaired image-to-image translation using cycle-consistent adversarial networks[C]// Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017: 2223-2232.

[17] Rombach R., Blattmann A., Lorenz D., et al. High-resolution image synthesis with latent diffusion models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022: 10684-10695.

[18] Lugmayr A., Danelljan M., Timofte R. RePaint: Inpainting using denoising diffusion probabilistic models[C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2022: 11461-11471.

[19] Lin T. Y., Maire M., Belongie S., et al. Microsoft COCO: Common objects in context[C]// European Conference on Computer Vision (ECCV). Springer, 2014: 740-755.

[20] Brvcket. SDXL-Inpainting-Lighting Dataset[EB/OL].Available: https://huggingface.co/datasets/Brvcket/sdxl-inpainting-lighting.